

# Lista 5 - MAE0330

Guilherme N<sup>o</sup>USP: 8943160 e Leonardo N<sup>o</sup>USP: 9793436

## Exercício 1

Os dados reproduzidos na tabela a seguir são referentes a atendimentos realizados no Hospital Universitário de Santa Maria (Rio Grande do Sul) entre os anos de 2000 a 2005 (Infantosi et al., 2014).

Os atendimentos foram divididos em 17 clínicas especializadas: Obstetrícia (Ob); Ginecologia (Gin); Clínica Cirúrgica Geral (C. Cir); Hematologia (Hemato); Hemodiálise-Diálise Peritoneal (Hemod); Clínica Médica Geral (CMG); CTI adultos (CTIA); Pediatria (P); UTI Pediátrica (UTI1); UTI de Recém-nascidos (UTI2); Unidade de Cuidados Intermediários Neonatal (UCI); Centro de Tratamento de Crianças com Câncer (CC); Centro de Tratamento de Medula Óssea (CMO); Pronto Atendimento de Adultos (PA) e Pronto Atendimento Pediátrico (PP); Serviço de Tratamento de Dependentes Químicos (DQ) e Clínica Paulo Guedes, para pacientes psiquiátricos (PPsq.). Os atendimentos foram classificados em: Internação (I), Transferências Recebidas (TR), Altas (AL), Transferências Enviadas (TE) e Óbitos (O). Essa classificação é frequentemente utilizada com indicador hospitalar.

Clínica	Indicador Hospitalar				
	I	TR	AL	TE	O
<b>Ob</b>	8968	3289	11933	228	2
<b>Gin</b>	2881	464	3187	109	63
<b>C. Cir</b>	3033	5468	7919	367	264
<b>Hemato</b>	2415	1646	3328	380	350
<b>Hemod</b>	1042	277	1061	198	57
<b>CMG</b>	522	2496	2250	382	421
<b>CTIA</b>	258	1483	77	1016	655
<b>P</b>	952	2112	2200	305	13
<b>UTI1</b>	479	613	186	764	149
<b>UTI2</b>	1541	280	230	1369	228
<b>UCI</b>	169	1355	1214	290	5
<b>CC</b>	2300	256	2357	125	27
<b>CMO</b>	328	40	305	65	7
<b>PA</b>	4049	94	2515	1660	20
<b>PP</b>	16524	45	6791	8986	824
<b>DQ</b>	2031	41	2024	40	0
<b>PPsq</b>	1834	41	1818	38	1

REFERÊNCIA: Infantosi, A. F. C., Costa, J. C. G. D., Almeida, R. M. V. R. (2014). Análise de Correspondência: bases teóricas na interpretação de dados categóricos em Ciências da Saúde. Cad. Saúde Pública, 30(3):473-486.

Faça o teste de qui-quadrado para avaliar se há associação entre as variáveis e obtenha a representação gráfica utilizando análise de correspondência. Obtenha as inércias e discuta os resultados encontrados.

## Resolução

Queremos testar a associação entre as variáveis, seguindo as seguintes hipóteses:

$$\begin{cases} H_0 : p_{ij} = (p_{i+})(p_{+j}), \text{ para } i = 1, \dots, 17 \text{ e } j = 1, \dots, 5 \\ H_1 : p_{ij} \neq (p_{i+})(p_{+j}), \text{ para pelo menos um par } (i, j) \end{cases}$$

Em que  $p_{ij}$  são as probabilidades conjuntas;

$p_{i+}$  são as probabilidades marginais-linha;

E  $p_{+j}$  são as probabilidades marginais-coluna

E a estatística do teste Qui-quadrado é:

$$Q_p = \sum_{i=1}^{17} \sum_{j=5}^5 \frac{(n_{ij} - e_{ij})^2}{e_{ij}} \sim \chi_{(17-1)*(5-1)=64}^2$$

Em que  $n_{ij}$  é o valor observado da  $i$ -ésima clínica e da  $j$ -ésimo atendimento;

E  $e_{ij}$  é o valor esperado da  $i$ -ésima clínica e da  $j$ -ésimo atendimento.

Considerando que as marginais-linha estão fixadas, realizando o teste temos:

```
##
## Pearson's Chi-squared test
##
## data:  dados1
## X-squared = 59731, df = 64, p-value < 2.2e-16
```

E com o seguinte resultado podemos concluir que com um nível de significância fixado de 5%, obtivemos um  $p - value < 0.0001$ , logo temos evidências estatísticas para dizer que há associação entre os atendimentos realizados e a clínica.

Fazendo a representação gráfica utilizando análise de correspondência, temos:


```
##
## Principal inertias (eigenvalues):
##
## dim    value      %   cum%   scree plot
## 1      0.255750  59.1  59.1  *****
## 2      0.159148  36.8  95.9  *****
## 3      0.017224   4.0  99.9  *
## 4      0.000309   0.1 100.0
##
## -----
## Total: 0.432431 100.0
##
##
## Rows:
##      name  mass  qlt  inr    k=1 cor ctr    k=2 cor ctr
## 1 |  Ob | 177  997  70 | 211 259 31 | -356 739 141 |
## 2 |  Gin |  49  915  21 |  35   6   0 | -414 909  52 |
## 3 | CCir | 123  983 119 | 639 979 197 |   43   4   1 |
## 4 | Hemt |  59  771  14 | 282 769  18 |   12   1   0 |
## 5 | Hemd |  19  789   2 |  -7   1   0 | -169 788   3 |
## 6 |  CMG |  44  991  83 | 751 687  97 |  499 303  69 |
```

```

## 7 | CTIA | 25 919 150 | 255 25 6 | 1512 894 363 |
## 8 | P | 40 876 50 | 658 816 68 | 177 59 8 |
## 9 | UTI1 | 16 972 34 | -163 28 2 | 937 944 88 |
## 10 | UTI2 | 26 999 56 | -714 555 53 | 638 443 68 |
## 11 | UCI | 22 848 46 | 797 696 55 | 372 152 19 |
## 12 | CC | 37 940 18 | -33 5 0 | -440 935 45 |
## 13 | CMO | 5 973 1 | -144 208 0 | -276 765 3 |
## 14 | PA | 60 966 35 | -479 914 54 | -114 52 5 |
## 15 | PP | 240 995 256 | -666 962 416 | 123 33 23 |
## 16 | DQ | 30 945 24 | -95 26 1 | -564 919 60 |
## 17 | PPsq | 27 944 21 | -95 27 1 | -560 918 53 |
##
## Columns:
##      name  mass  qlt  inr    k=1 cor ctr    k=2 cor ctr
## 1 | I | 357 993 134 | -353 765 174 | -192 228 83 |
## 2 | TR | 145 991 343 | 889 771 447 | 475 220 205 |
## 3 | AL | 358 997 123 | 253 433 90 | -289 564 188 |
## 4 | TE | 118 977 288 | -792 594 289 | 636 383 300 |
## 5 | O | 22 736 112 | 11 0 0 | 1262 735 224 |

```

E o gráfico utilizando a dimensão=2, seguindo o scree-plot pois acumulou uma inércia de 95%, temos:



Pode-se interpretar o gráfico da seguinte forma:

- A especialização de Obstetrícia está fortemente associada ao atendimento de Altas. Hematologia também está associada a este atendimento. Hemodiálise-Diálise Peritoneal, Centro de Tratamento de Medula Óssea, Ginecologia, Centro de Tratamento de Crianças com Câncer, Serviço de Tratamento de Dependentes Químicos e Clínica Paulo Guedes, para pacientes psiquiátricos estão associados a Altas e Internação.
- Pronto Atendimento de Adultos também está associada a Internações. E Pronto Atendimento Pediátrico está associada com Internações e Transferências Enviadas. Associada a esta última, está UTI de Recém-nascidos.

- UTI Pediátrica está associada com Transferências Enviadas e Óbitos.
- Os pacientes de CTI adultos estão associados com Óbitos.
- Clínica Médica Geral e Unidade de Cuidados Intermediários Neonatal estão associados com Transferências Recebidas.
- Por fim, Clínica Cirúrgica Geral e Pediatria estão associados com Transferências Recebidas e Altas.

## Exercício 2

A tabela a seguir considera a distribuição do número de bulbilhos de alho de acordo com a categoria de tamanho (7-5, 4 e <4), tratamento e ano sequencial de replantio. Os tratamentos são:

- Tratamento Padrão (P): Bulbos tratados com fungicida conforme recomendação do fabricante;
- Tratamento Teste (T): Bulbos infectados.

Ano	Tratamento	Tamanho dos bulbilhos			Total
		7-5	4	menor que 4	
2011	Padrão	417	36	0	453
	Teste	164	176	90	430
2012	Padrão	357	27	0	384
	Teste	169	161	54	384
2013	Padrão	800	240	103	1143
	Teste	412	458	274	1144
2014	Padrão	273	176	39	488
	Teste	185	220	83	488
2015	Padrão	1521	1794	585	3900
	Teste	1420	1681	635	3736

Realize uma Análise de Correspondência destes dados. Justifique e interprete os resultados. Bulbilhos de tamanhos maiores estão associados a qual tratamento, em que ano?

### Resolução

Fazendo a análise de correspondência, temos:

```
## , , Ano = 2011
##
##           Tratamento
## Tam_Bulbilhos Padrao Teste
##           <4         0      90
##           4          36     176
##           7-5       417     164
##
## , , Ano = 2012
##
##           Tratamento
## Tam_Bulbilhos Padrao Teste
##           <4         0      54
##           4          27     161
```


```

##          7-5    357    169
##
## , , Ano = 2013
##
##          Tratamento
## Tam_Bulbilhos Padrao Teste
##          <4      103    274
##          4       240    458
##          7-5     800    412
##
## , , Ano = 2014
##
##          Tratamento
## Tam_Bulbilhos Padrao Teste
##          <4       39     83
##          4       176    220
##          7-5     273    185
##
## , , Ano = 2015
##
##          Tratamento
## Tam_Bulbilhos Padrao Teste
##          <4      585    635
##          4      1794   1681
##          7-5    1521   1420
##
##
## Principal inertias (eigenvalues):
##
## dim    value      %   cum%   scree plot
## 1      0.173326  21.9  21.9   *****
## 2      0.127952  16.1  38.0   ****
## 3      0.112228  14.2  52.1   ****
## 4      0.111111  14.0  66.2   ***
## 5      0.110073  13.9  80.0   ***
## 6      0.096479  12.2  92.2   ***
## 7      0.061794   7.8 100.0   **
##          -----
## Total: 0.792963 100.0
##
##
## Columns:
##          name    mass  qlt  inr    k=1 cor ctr    k=2 cor ctr
## 1 | Tam_Bulbilhos:<4 |    49  584  121 |  512 135  75 | -933 449 337 |
## 2 | Tam_Bulbilhos:4 |   132  651   88 |  452 389 156 |  372 262 142 |
## 3 | Tam_Bulbilhos:7-5 |   152  741   81 | -560 740 275 |  -19   1   0 |
## 4 | Tratamento:Padrao |   169  457   71 | -298 267  86 |  251 190  83 |
## 5 | Tratamento:Teste |   164  457   73 |  307 267  89 | -258 190  86 |
## 6 |          Ano:2011 |    23  171  132 | -847 161  97 | -211  10   8 |
## 7 |          Ano:2012 |    20  170  133 | -933 168 102 |  118   3   2 |
## 8 |          Ano:2013 |    61  418  115 | -280  52  27 | -743 366 262 |
## 9 |          Ano:2014 |    26   22  129 |  -43   0   0 |  294  22  18 |
## 10 |          Ano:2015 |   203  533   57 |  281 357  92 |  197 176  62 |

```

Uma observação a se fazer é que utilizando a tabela indicadora o gráfico com duas dimensões temos uma inércia acumulada de 51%, em contrapartida com a tabela de Burt, a inércia acumulada para duas dimensões é de 59,9%, justificando o fato de escolher a tabela de Burt como parâmetro para o MCA.

E o gráfico em duas dimensões:



Em que podemos notar que pela ordem cronológica temos:

- No ano de 2011, não é possível distinguir qual Tratamento está mais associado mas o Tamanho dos bulbilhos de 7-5 estão mais associados.
- No ano de 2012, aparentemente o Tratamento padrão e o Tamanho de 7-5 estão mais associados ao ano.
- Em 2013, o Tratamento mais associado é o teste, juntamente com o Tamanho <4.
- Para o ano de 2014 e 2015, o Tratamento é o Padrão e o tamanho 4 estão mais associados.

### Exercício 3

Em um estudo feito com 49 meninos e 61 meninas, foram aplicados testes psicológicos de inteligência para avaliar compreensão verbal (V), capacidade espacial (S), raciocínio geral (R), capacidade numérica (N) e fluência verbal (W). Os testes foram aplicados em dois momentos, com diferença de 3 anos e meio entre eles. A matriz de correlação está apresentada a seguir. Utilizando o comando `ca` do pacote `lavaan` do R, ajuste um modelo de análise fatorial confirmatória com 1 único fator que explique todas as aptidões em cada ano (ou seja, temos dois fatores no total, um para cada anos). Escreva o modelo ajustado e faça o desenho do diagrama de caminhos com os valores estimados.

	V:t <sub>1</sub>	S:t <sub>1</sub>	R:t <sub>1</sub>	N:t <sub>1</sub>	W:t <sub>1</sub>	V:t <sub>2</sub>	S:t <sub>2</sub>	R:t <sub>2</sub>	N:t <sub>2</sub>	W:t <sub>2</sub>
V:t <sub>1</sub>	1.00	0.37	0.42	0.53	0.38	0.81	0.35	0.42	0.40	0.24
S:t <sub>1</sub>	0.37	1.00	0.33	0.14	0.10	0.34	0.65	0.32	0.14	0.15
R:t <sub>1</sub>	0.42	0.33	1.00	0.38	0.20	0.49	0.20	0.75	0.39	0.17
N:t <sub>1</sub>	0.53	0.14	0.38	1.00	0.24	0.58	-0.04	0.46	0.73	0.15
W:t <sub>1</sub>	0.38	0.10	0.20	0.24	1.00	0.32	0.11	0.26	0.19	0.43
V:t <sub>2</sub>	0.81	0.34	0.49	0.58	0.32	1.00	0.34	0.46	0.55	0.24
S:t <sub>2</sub>	0.35	0.65	0.20	-0.04	0.11	0.34	1.00	0.18	0.06	0.15
R:t <sub>2</sub>	0.42	0.32	0.75	0.46	0.26	0.46	0.18	1.00	0.54	0.20
N:t <sub>2</sub>	0.40	0.14	0.39	0.73	0.19	0.55	0.06	0.54	1.00	0.16
W:t <sub>2</sub>	0.24	0.15	0.17	0.15	0.43	0.24	0.15	0.20	0.16	1.00

## Resolução

```
## lavaan 0.6-5 ended normally after 35 iterations
##
## Estimator ML
## Optimization method NLMINB
## Number of free parameters 26
##
## Number of observations 100
##
## Model Test User Model:
##
## Test statistic 47.208
## Degrees of freedom 29
## P-value (Chi-square) 0.018
##
## Parameter Estimates:
##
## Information Expected
## Information saturated (h1) model Structured
## Standard errors Standard
##
## Latent Variables:
## Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## Ano1 =~
## Vt1 1.000 0.764 0.770
## St1 0.528 0.148 3.568 0.000 0.404 0.405
## Rt1 0.749 0.152 4.915 0.000 0.572 0.579
## Nt1 0.906 0.163 5.551 0.000 0.692 0.688
## Wt1 0.517 0.148 3.481 0.000 0.395 0.397
## Ano2 =~
## Vt2 1.000 0.835 0.838
## St2 0.374 0.131 2.847 0.004 0.312 0.313
## Rt2 0.721 0.133 5.417 0.000 0.603 0.611
## Nt2 0.785 0.139 5.666 0.000 0.656 0.657
## Wt2 0.348 0.132 2.632 0.008 0.290 0.292
##
## Regressions:
## Estimate Std.Err z-value P(>|z|) Std.lv Std.all
```

```

##   Ano2 ~
##     Ano1           1.042    0.102   10.208    0.000    0.953    0.953
##
## Covariances:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
##   .Vt1 ~~
##   .Vt2           0.191    0.086    2.217    0.027    0.191    0.557
##   .St1 ~~
##   .St2           0.530    0.105    5.030    0.000    0.530    0.614
##   .Rt1 ~~
##   .Rt2           0.389    0.087    4.455    0.000    0.389    0.619
##   .Nt1 ~~
##   .Nt2           0.314    0.085    3.696    0.000    0.314    0.573
##   .Wt1 ~~
##   .Wt2           0.319    0.096    3.311    0.001    0.319    0.366
##
## Variances:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
##   .Vt1           0.400    0.102    3.922    0.000    0.400    0.406
##   .St1           0.832    0.124    6.721    0.000    0.832    0.836
##   .Rt1           0.649    0.106    6.110    0.000    0.649    0.665
##   .Nt1           0.533    0.102    5.240    0.000    0.533    0.527
##   .Wt1           0.834    0.124    6.736    0.000    0.834    0.843
##   .Vt2           0.295    0.099    2.972    0.003    0.295    0.297
##   .St2           0.895    0.130    6.890    0.000    0.895    0.902
##   .Rt2           0.610    0.102    5.986    0.000    0.610    0.627
##   .Nt2           0.565    0.102    5.559    0.000    0.565    0.568
##   .Wt2           0.907    0.131    6.916    0.000    0.907    0.915
##   .Ano1          0.584    0.152    3.829    0.000    1.000    1.000
##   .Ano2          0.064    0.039    1.663    0.096    0.092    0.092

```

Podemos portanto escrever os modelos como:

$$Ano_1 = Vt_1 + 0.528 * St_1 + 0.749 * Rt_1 + 0.906 * Nt_1 + 0.517 * Wt_1$$

$$Ano_2 = Vt_2 + 0.374 * St_2 + 0.721 * Rt_2 + 0.785 * Nt_2 + 0.348 * Wt_2$$

$$Ano_2 = 1.042 * Ano_1$$

$$cov(Vt_1, Vt_2) = 0.191$$

$$cov(St_1, St_2) = 0.530$$

$$cov(Rt_1, Rt_2) = 0.389$$

$$cov(Nt_1, Nt_2) = 0.314$$

$$cov(Wt_1, Wt_2) = 0.319$$



$$Var(Vt_1) = 0.400$$

$$Var(St_1) = 0.832$$

$$Var(Rt_1) = 0.649$$

$$Var(Nt_1) = 0.533$$

$$Var(Wt_1) = 0.834$$

$$Var(Vt_2) = 0.295$$

$$Var(St_2) = 0.895$$

$$Var(Rt_2) = 0.610$$


$$Var(Nt_2) = 0.565$$

$$Var(Wt_2) = 0.907$$

$$Var(Ano_1) = 0.584$$

$$Var(Ano_2) = 0.064$$

E o diagrama de caminhos:



## Códigos

```
# Lista 5 - Multivariada - MAE0330

library(ggplot2)
library(ca)
library(lavaan)
library(expm)
library(tidyr)

# exercício 1

# leitura dos dados
M1 <- t(matrix(c(8968,3289,11933,228,2,
                2881,464,3187,109,63,
                3033,5468,7919,367,264,
                2415,1646,3328,380,350,
                1042,277,1061,198,57,
                522,2496,2250,382,421,
                258,1483,77,1016,655,
                952,2112,2200,305,13,
                479,613,186,764,149,
                1541,280,230,1369,228,
                169,1355,1214,290,5,
                2300,256,2357,125,27,
                328,40,305,65,7,
                4049,94,2515,1660,20,
                16524,45,6791,8986,824,
                2031,41,2024,40,0,
                1834,41,1818,38,1),5,17))

dados1 <- as.data.frame(M1)
names(dados1) <- c("I", "TR", "AL", "TE", "O")
row.names(dados1) <- c("Ob", "Gin", "C.Cir", "Hemato", "Hemod",
                       "CMG", "CTIA", "P", "UTI1", "UTI2", "UCI",
                       "CC", "CMO", "PA", "PP", "DQ", "PPsq")

# teste qui-quadrado
chisq.test(dados1)

# Analise de correspondencia
A.corresp <- ca(dados1)
summary(A.corresp)

# para gráfico

n <- sum(M1)
P <- M1/n

vr <- P%%rep(1,ncol(M1))
vc <- t(P)%%rep(1,nrow(M1))
Dr <- diag(c(vr))
Dc <- diag(c(vc))
```

```

S <- sqrtm(solve(Dr))%*(P-vr%*t(vc))%*sqrtm(solve(Dc))
dvs_S <- svd(S)
M_X1 <- sqrtm(solve(Dr))%*dvs_S$u[,1:2]%*diag(dvs_S$d[1:2])
M_Y2 <- sqrtm(solve(Dc))%*dvs_S$v[,1:2]%*diag(dvs_S$d[1:2])

dados_grafico <- data.frame(rbind(M_X1,M_Y2))
dados_grafico$tipo <- factor(c(rep(1,17),rep(2,5)))
rownames(dados_grafico) <- c("Ob","Gin","C.Cir","Hemato","Hemod",
                             "CMG","CTIA","P","UTI1","UTI2","UCI",
                             "CC","CMO","PA","PP","DQ","PPsq","I",
                             "TR","AL","TE","O")

dados_grafico %>%
  ggplot(aes(x = X1, y = X2, shape=factor(tipo), colour=factor(tipo))) +
  geom_point() +
  geom_hline(yintercept = 0, colour = "gray70") +
  geom_vline(xintercept = 0, colour = "gray70") +
  geom_text(aes(y=X2+0.08,label= rownames(dados_grafico))) +
  guides(colour=FALSE, shape=FALSE) +
  labs(x="Dim 1 (59.1%)",
       y="Dim 2 (36.8%)",
       title="Clinicas e atendimentos realizados")

# Exercício 2

# Entrada dos dados

c1 <- matrix(c("7-5","Padrao","2011"),417,3,byrow = TRUE)
c2 <- matrix(c("4","Padrao","2011"),36,3,byrow = TRUE)
c3 <- matrix(c("7-5","Teste","2011"),164,3,byrow = TRUE)
c4 <- matrix(c("4","Teste","2011"),176,3,byrow = TRUE)
c5 <- matrix(c("<4","Teste","2011"),90,3,byrow = TRUE)

c6 <- matrix(c("7-5","Padrao","2012"),357,3,byrow = TRUE)
c7 <- matrix(c("4","Padrao","2012"),27,3,byrow = TRUE)
c8 <- matrix(c("7-5","Teste","2012"),169,3,byrow = TRUE)
c9 <- matrix(c("4","Teste","2012"),161,3,byrow = TRUE)
c10 <- matrix(c("<4","Teste","2012"),54,3,byrow = TRUE)

c11 <- matrix(c("7-5","Padrao","2013"),800,3,byrow = TRUE)
c12 <- matrix(c("4","Padrao","2013"),240,3,byrow = TRUE)
c13 <- matrix(c("<4","Padrao","2013"),103,3,byrow = TRUE)
c14 <- matrix(c("7-5","Teste","2013"),412,3,byrow = TRUE)
c15 <- matrix(c("4","Teste","2013"),458,3,byrow = TRUE)
c16 <- matrix(c("<4","Teste","2013"),274,3,byrow = TRUE)

c17 <- matrix(c("7-5","Padrao","2014"),273,3,byrow = TRUE)
c18 <- matrix(c("4","Padrao","2014"),176,3,byrow = TRUE)
c19 <- matrix(c("<4","Padrao","2014"),39,3,byrow = TRUE)
c20 <- matrix(c("7-5","Teste","2014"),185,3,byrow = TRUE)
c21 <- matrix(c("4","Teste","2014"),220,3,byrow = TRUE)
c22 <- matrix(c("<4","Teste","2014"),83,3,byrow = TRUE)

```

```

c23 <- matrix(c("7-5", "Padrao", "2015"), 1521, 3, byrow = TRUE)
c24 <- matrix(c("4", "Padrao", "2015"), 1794, 3, byrow = TRUE)
c25 <- matrix(c("<4", "Padrao", "2015"), 585, 3, byrow = TRUE)
c26 <- matrix(c("7-5", "Teste", "2015"), 1420, 3, byrow = TRUE)
c27 <- matrix(c("4", "Teste", "2015"), 1681, 3, byrow = TRUE)
c28 <- matrix(c("<4", "Teste", "2015"), 635, 3, byrow = TRUE)

dados2 <- rbind(c1, c2, c3, c4, c5, c6, c7, c8, c9, c10,
               c11, c12, c13, c14, c15, c16, c17, c18, c19, c20,
               c21, c22, c23, c24, c25, c26, c27, c28)

dados2 <- data.frame(dados2)
names(dados2) <- c("Tam_Bulbilhos", "Tratamento", "Ano")

table(dados2)

# Analise de correspondencia
A.corresp.M <- mja(dados2, lambda="indicator")

summary(A.corresp.M)

g <- plot(A.corresp.M, labels=c(2,2), map="symmetric")

dados_grafico1 <- data.frame(g$cols)
row.names(dados_grafico1) <- row.names(g$cols)

dados_grafico1 %>%
  ggplot(aes(x = Dim1, y = Dim2)) +
  geom_point() +
  geom_hline(yintercept = 0, colour = "gray70") +
  geom_vline(xintercept = 0, colour = "gray70") +
  scale_x_continuous(limits = c(-2, 1.5)) +
  geom_text(aes(y=Dim2+0.08, label= rownames(dados_grafico1))) +
  guides(colour=FALSE, shape=FALSE) +
  labs(x="Dim 1 (21.9%)",
       y="Dim 2 (38.0%)",
       title="Bulbilhos de alho por tamanho tratamento e ano de plantio")

library(lavaan)
M.cor <- data.frame(matrix(c(1.00, 0.37, 0.42, 0.53, 0.38, 0.81, 0.35, 0.42, 0.40, 0.24,
                           0.37, 1.00, 0.33, 0.14, 0.10, 0.34, 0.65, 0.32, 0.14, 0.15,
                           0.42, 0.33, 1.00, 0.38, 0.20, 0.49, 0.20, 0.75, 0.39, 0.17,
                           0.53, 0.14, 0.38, 1.00, 0.24, 0.58, -0.04, 0.46, 0.73, 0.15,
                           0.38, 0.10, 0.20, 0.24, 1.00, 0.32, 0.11, 0.26, 0.19, 0.43,
                           0.81, 0.34, 0.49, 0.58, 0.32, 1.00, 0.34, 0.46, 0.55, 0.24,
                           0.35, 0.65, 0.20, -0.04, 0.11, 0.34, 1.00, 0.18, 0.06, 0.15,
                           0.42, 0.32, 0.75, 0.46, 0.26, 0.46, 0.18, 1.00, 0.54, 0.20,
                           0.40, 0.14, 0.39, 0.73, 0.19, 0.55, 0.06, 0.54, 1.00, 0.16,
                           0.24, 0.15, 0.17, 0.15, 0.43, 0.24, 0.15, 0.20, 0.16, 1.00), 10, 10))

names(M.cor) <- c("Vt1", "St1", "Rt1", "Nt1", "Wt1", "Vt2", "St2", "Rt2", "Nt2", "Wt2")

```

```

rownames(M.cor) <- c("Vt1","St1","Rt1","Nt1","Wt1","Vt2","St2","Rt2","Nt2","Wt2")

lower <- '
          1.00,
          0.37,1.00,
          0.42,0.33,1.00,
          0.53,0.14,0.38,1.00,
          0.38,0.10,0.20,0.24,1.00,
          0.81,0.34,0.49,0.58,0.32,1.00,
          0.35,0.65,0.20,-0.04,0.11,0.34,1.00,
          0.42,0.32,0.75,0.46,0.26,0.46,0.18,1.00,
          0.40,0.14,0.39,0.73,0.19,0.55,0.06,0.54,1.00,
          0.24,0.15,0.17,0.15,0.43,0.24,0.15,0.20,0.16,1.00'
# convert to a full symmetric covariance matrix with names
wheaton.cov <- getCov(lower,
                      names=c("Vt1","St1","Rt1","Nt1","Wt1",
                              "Vt2","St2","Rt2","Nt2","Wt2"))

model <- '
# measurement model
Ano1 =~ Vt1 + St1 + Rt1 + Nt1 + Wt1
Ano2 =~ Vt2 + St2 + Rt2 + Nt2 + Wt2
# regressions
Ano2 ~ Ano1
# residual correlations
Vt1 ~~ Vt2
St1 ~~ St2
Rt1 ~~ Rt2
Nt1 ~~ Nt2
Wt1 ~~ Wt2
'

fit <- sem(model, sample.cov=wheaton.cov, sample.nobs=100)
summary(fit, standardized=TRUE)

library(semPlot)
semPaths(fit)

```